

GESTIÓN DE SISTEMAS DE DATOS MASIVOS

Scientific Workshop

Contenido

A lo largo de la asignatura hemos abordado tres grandes áreas de la gestión de datos masivos:

- **Almacenamiento de Datos**: cómo obtener, transformar, organizar y almacenar grandes volúmenes de datos.
- **Recuperación de Información:** cómo representar, indexar, buscar y recuperar información relevante.
- **Gobernanza e Interoperabilidad**: cómo integrar y compartir los datos entre sistemas.

BLOQUE I: Almacenamiento de Datos

1. **Fuentes e ingesta de datos**
    1. Datos estructurados y no estructurados.
    2. Obtención de datos: APIs, archivos y web scraping.
    3. Preprocesamiento, limpieza y transformación de datos.
2. **Integración y transformación**
    1. Arquitecturas ETL y ELT.
    2. Transformaciones clásicas y avanzadas.
    3. Integración de fuentes heterogéneas.
3. **Almacenamiento y análisis**
    1. Escalabilidad vertical y horizontal.
    2. Sistemas transaccionales (OLTP) y analíticos (OLAP).
    3. Data Warehouse y modelado dimensional.
    4. Esquemas estrella (*Star*) y copo de nieve (*Snowflake*).
    5. Procesamiento distribuido con Apache Hive y HiveQL.

BLOQUE II: Recuperación de Información

1. **Representación e indexación**
    1. Índices invertidos.
    2. Representación de documentos y consultas.
2. **Recuperación léxica**
    1. Modelos booleanos y vectoriales (TF-IDF y BM25).
    2. Ranking, filtrado y búsqueda de texto completo.
    3. Evaluación: Precision, Recall y nDCG.
3. **Recuperación semántica**
    1. Representaciones vectoriales (*embeddings*).
    2. Indexación aproximada: ANN y HNSW.
    3. Recuperación híbrida: léxica + semántica.
4. **Generación aumentada con recuperación**
    1. Arquitecturas Retrieval-Augmented Generation (RAG).
    2. Recuperación, construcción del contexto y generación.

BLOQUE III: Gobernanza e Interoperabilidad

1. **Representación semántica de datos**
    1. Web Semántica y Linked Data.
    2. RDF: recursos, propiedades y tripletas.
2. **Modelado del conocimiento**
    1. Vocabularios y esquemas: RDFS.
    2. Ontologías y OWL.
3. **Publicación y consulta**
    1. Almacenamiento en bases de datos RDF (*triplestores*).
    2. Consultas SPARQL y endpoints.
    3. Integración de datos mediante grafos de conocimiento.
4. **Gobernanza e intercambio de datos**
    1. Espacios de datos (*Data Spaces*).
    2. Catálogos y metadatos: DCAT.
    3. Políticas de acceso y uso: ODRL.

Actividad

- Seleccionar uno de los **conceptos** vistos en clase y buscar un **trabajo científico** que investigue algún problema relacionado con él.

- El objetivo no es explicar nuevamente la tecnología, sino descubrir la **contribución científica**:
  - ¿Qué problema intenta resolver?
  - ¿Por qué es importante?
  - ¿Qué solución o aproximación proponen los autores?
  - ¿Cómo han evaluado su propuesta?
  - ¿Qué resultados obtienen?
  - ¿Qué limitaciones o cuestiones abiertas identificáis?

- Cada grupo de estudiantes analizará un trabajo científico y preparará un **póster** para presentarlo en el **workshop** el último día de la asignatura.

- No es necesario cubrir todos los conceptos del bloque: basta con seleccionar **uno** o **varios** que estén directamente relacionados con el **artículo**.

Selección de Artículo Científico

- Se seleccionará un artículo publicado en una revista científica o congreso internacional, preferentemente de los **últimos 5 años**, que cumpla alguno de los siguientes requisitos:

1. **Revistas científicas**
    1. Publicación en una revista clasificada como Q1, Q2 o Q3 (JCR o SCImago/SJR)
2. **Congresos científicos**
    1. Artículo publicado en un congreso clasificado como A*, A o B en CORE/ICORE.
    2. Comprobar que el artículo pertenece a las actas científicas del congreso y no simplemente a un workshop asociado.

- **Para validar la elección se deberá identificar:**
    - Título, autores y año.
    - Revista o congreso de publicación.
    - DOI o enlace permanente.

- **Importante:** no basta con encontrar una publicación que mencione una tecnología. El trabajo debe investigar un problema relacionado con ella.

Preparación del póster científico 1/2

1. **Identificación**
   1. Título del artículo, autores, año y publicación.
   2. Referencia bibliográfica y DOI.
2. **Motivación y problema**
   1. ¿Qué problema de investigación aborda?
   2. ¿Por qué es relevante?
3. **Propuesta**
   1. ¿Cuál es la principal contribución?
   2. ¿Qué método, arquitectura o técnica utilizan?
4. **Evaluación y resultados**
   1. ¿Cómo validan su propuesta?
   2. ¿Con qué datos, experimentos o métricas?
   3. ¿Cuáles son los principales resultados?

Preparación del póster científico 2/2

5. **Análisis crítico**
    1. ¿Qué ventajas y limitaciones presenta?
    2. ¿Qué preguntas quedan abiertas?

6. **Relación con la asignatura**
    1. ¿Qué conceptos de la asignatura aparecen en el trabajo?
    2. ¿En qué amplía o mejora lo estudiado en clase?

- El póster debe ser **visual**, **claro** y **sintético**. Se recomienda utilizar diagramas, tablas o figuras para explicar la propuesta y sus resultados.

- No queremos únicamente un resumen del artículo: queremos que demostréis que habéis **comprendido su contribución científica**.

Scientific Workshop

- El último día de clase organizaremos un **workshop científico** en el que cada grupo de estudiantes presentará su póster al resto de la clase.

- **Dinámica**
  1. Exposición breve del trabajo seleccionado, utilizando el póster como soporte.
  2. Explicación del problema, la contribución y los principales resultados.
  3. Relación del trabajo con alguno de los contenidos de la asignatura.
  4. Preguntas y discusión con el resto de los participantes.

- **¿Qué valoraremos?**
  - La adecuación y calidad científica del artículo seleccionado.
  - La comprensión del problema y de la propuesta.
  - La relación con los conceptos estudiados.
  - La calidad visual del póster y la capacidad de comunicar y discutir el trabajo.



POLITÉCNICA

UNIVERSIDAD
POLITÉCNICA
DE MADRID



Universidad
Politécnica
de Madrid

ETSI **SISTEMAS INFORMÁTICOS**