UNIVERSIDAD POLITÉCNICA DE MADRID · ETSISI · MÁSTER EN APRENDIZAJE AUTOMÁTICO Y DATOS MASIVOS

Propuestas de Artículos Científicos — Scientific Workshop

Asignatura: Gestión de Sistemas de Datos Masivos · Selección verificada (JCR Q1 / CORE A*-A, 2023–2025) con enlaces funcionales

Checklist de Requisitos del Póster y del Artículo (según 4_Workshop.pdf)

- **Requisitos del paper:** Últimos 5 años; Revista **JCR/SJR Q1–Q3** o Congreso **CORE A*, A o B** (*Main Proceedings*, no workshops).
- **Datos para validar:** Título, autores, año, revista/congreso y enlace permanente (**DOI**).
- **Enfoque:** Investigar un **problema científico**, no describir la tecnología.
- **Estructura del Póster (6 secciones):** 1. Identificación (Título, autores, año, venue, DOI) · 2. Motivación y problema · 3. Propuesta (contribución y arquitectura) · 4. Evaluación y resultados (datasets y métricas) · 5. Análisis crítico (ventajas, limitaciones, retos) · 6. Relación con la asignatura.

BLOQUE I: Almacenamiento de Datos (Ingesta, ETL/ELT, Data Warehouse, Apache Hive) Página 1 · 3 Opciones

Opción 1.1 — Petabyte-Scale Row-Level Operations in Data Lakehouses

★ RECOMENDADO BLOQUE I · CORE A* (VLDB) · JCR Q1

Autores: Anton Okolnychyi, Chao Sun, Kazuyuki Tanimura, Russell Spitzer, Ryan Blue, Szehon Ho, Yufei Gu, Vishwanath Lakkundi, DB Tsai (Apple & Netflix) · **Año:** 2024 · **Publicación:** *Proceedings of the VLDB Endowment (PVLDB)*, Vol. 17, No. 12, pp. 4159–4172.

DOI Oficial: https://doi.org/10.14778/3685800.3685834

PDF Completo (VLDB): https://www.vldb.org/pvldb/vol17/p4159-okolnychyi.pdf

- **Problema de investigación:** Los almacenes analíticos distribuidos clásicos como **Apache Hive** están diseñados para *batch* y sufren graves cuellos de botella al ejecutar operaciones transaccionales ACID a nivel de fila (`UPDATE`, `DELETE`, `MERGE`) sobre ficheros columnares inmutables a escala de petabytes.
- **Contribución científica:** Analiza y optimiza las estrategias *Copy-on-Write (CoW)* frente a *Merge-on-Read (MoR)* en Apache Iceberg/Spark mediante optimizaciones de distribución inspiradas en bases de datos paralelas y vectores de borrado, reduciendo los tiempos de ejecución en un orden de magnitud.
- **Conexión con la asignatura:** Conecta directamente con *B2_2_Warehouse_2025.pdf* (OLTP vs. OLAP, Data Warehouse, arquitectura **Apache Hive ACID / tablas ORC** y las limitaciones de HiveQL de las diapositivas 17–21).

Opción 1.2 — LST-Bench: Benchmarking Log-Structured Tables in the Cloud

CORE A* (SIGMOD) · ACM PACMMOD

Autores: Jesús Camacho-Rodríguez, Ashvin Agrawal, Anja Gruenheid, Ashit Gosalia, Cristian Petculescu, Josep Aguilar-Saborit, Avrilia Floratou, Carlo Curino, Raghu Ramakrishnan (Microsoft) · **Año:** 2024 · **Publicación:** *Proceedings of the ACM on Management of Data (SIGMOD 2024)*, Vol. 2, No. 1, Art. 56.

DOI Oficial: https://doi.org/10.1145/3639314 **PDF Completo (Acceso Abierto):** https://arxiv.org/pdf/2305.01120

- **Problema de investigación:** Cómo evaluar sistemáticamente el rendimiento, la degradación en el tiempo y la eficiencia de los formatos de tablas transaccionales en Data Warehouses distribuidos (evolución de **Apache Hive ACID**: Delta Lake, Apache Iceberg y Apache Hudi).
- **Contribución científica:** Propone el primer benchmark estándar (basado en el esquema dimensional TPC-DS) que mide el impacto de ingesta continua ETL/ELT, compactación, viajes en el tiempo y consultas OLAP.
- **Conexión con la asignatura:** El primer autor es desarrollador clave de **Apache Hive**; enlaza con esquemas estrella/copo de nieve, OLAP y procesamiento distribuido en *B2_2_Warehouse_2025.pdf*.

Opción 1.3 — Language Models Enable Simple Systems for Generating Structured Views of Heterogeneous Data Lakes

CORE A* (VLDB) · JCR Q1

Autores: Simran Arora, Brandon Yang, Sabri Eyuboglu, Avanika Narayan, Andrew Hojel, Immanuel Trummer, Christopher Ré (Stanford University) · **Año:** 2023 · **Publicación:** *Proceedings of the VLDB Endowment (PVLDB)*, Vol. 17, No. 2, pp. 92–105.

DOI Oficial: https://doi.org/10.14778/3626292.3626294 **PDF Completo (VLDB):** https://www.vldb.org/pvldb/vol17/p92-arora.pdf

- **Problema de investigación:** Transformar documentos no estructurados o semi-estructurados (HTML de web scraping, PDFs médicos, textos) en tablas estructuradas requiere costosos pipelines ETL diseñados manualmente por expertos de dominio.
- **Contribución científica:** Presenta **EVAPORATE-CODE**, que en lugar de procesar cada documento con un LLM (inviable a escala masiva), utiliza el LLM para generar múltiples funciones Python de extracción (con `BeautifulSoup`/regex) y las combina mediante *weak supervision*, reduciendo el coste en 110× y mejorando el F1-score.
- **Conexión con la asignatura:** Conecta al 100% con *B1_1_4_Fuentres De Datos.pdf* (paso de datos no estructurados a estructurados, parsing HTML con `BeautifulSoup`) y *B2_2_2_Gestión De Informacion.pdf* (ETL vs. ELT, transformaciones *Model-driven* y *Data-driven*).

BLOQUE II: Recuperación de Información (BM25, Embeddings, HNSW, Búsqueda Híbrida y RAG)

Página 2 · 3 Opciones

Opción 2.1 — An Analysis of Fusion Functions for Hybrid Retrieval

★ RECOMENDADO BLOQUE II | JCR Q1 (ACM TOIS)

Autores: Sebastian Bruch, Siyu Gai, Amir Ingber (Pinecone) · **Año:** 2023 · **Publicación:** *ACM Transactions on Information Systems (TOIS)*, Vol. 42, No. 1, Art. 20, pp. 1–35.

DOI Oficial: https://doi.org/10.1145/3596512 **PDF Completo (ACM):** https://dl.acm.org/doi/pdf/10.1145/3596512

arXiv: https://arxiv.org/pdf/2210.11934

- **Problema de investigación:** Al combinar recuperación léxica (**BM25**) y semántica (**Embeddings vectoriales**) en búsqueda híbrida, cómo deben fusionarse ambas listas: mediante *Score Fusion* (combinación convexa de puntuaciones normalizadas) o mediante *Rank Fusion* (**Reciprocal Rank Fusion - RRF**).
- **Contribución científica:** Demuestra teórica y empíricamente (sobre MS MARCO y BEIR usando **nDCG@10** y **Recall@k**) que RRF pierde información valiosa al descartar las puntuaciones subyacentes y es sensible a su constante *k*, mientras que la combinación convexa normalizada supera consistentemente a RRF con un ajuste mínimo.
- **Conexión con la asignatura:** Aborda literalmente la diapositiva 23 (*"Combining Lexical and Semantic Retrieval: Score Fusion vs. RRF"*) y la práctica Q4 de *2_2_Semantic_Retrieval_RAG.pdf*, además de las métricas de *2_1_1_Indexing_and_Information_Retrieval.pdf*.

Opción 2.2 — ACORN: Performant and Predicate-Agnostic Search Over Vector Embeddings and Structured Data

CORE A* (SIGMOD) | ACM PACMMOD

Autores: Liana Patel, Peter Kraft, Carlos Guestrin, Matei Zaharia (Stanford University & UC Berkeley) · **Año:** 2024 · **Publicación:** *Proceedings of the ACM on Management of Data (SIGMOD 2024)*, Vol. 2, No. 3, Art. 140.

DOI Oficial: https://doi.org/10.1145/3654923 **PDF Completo (ACM):** https://dl.acm.org/doi/pdf/10.1145/3654923

arXiv: https://arxiv.org/pdf/2403.04871

- **Problema de investigación:** Cuando se combina una búsqueda vectorial aproximada **ANN (HNSW)** con filtros de metadatos estructurados (ej. `rating >= 4` o `movie_title = "Avatar"`), los grafos HNSW pierden conectividad al descartar nodos que no cumplen el filtro, desplomándose el **ANN Recall@k** o disparando la latencia.
- **Contribución científica:** Propone **ACORN**, un algoritmo de construcción y navegación sobre grafos jerárquicos tipo **HNSW** que emula la propiedad *small-world* sobre el subgrafo inducido por cualquier predicado de filtrado, logrando aceleraciones de 2× a 1.000× con alto Recall@10.
- **Conexión con la asignatura:** Une el algoritmo **HNSW** (diap. 22 de *2_2_Semantic_Retrieval_RAG.pdf*) con la combinación de búsqueda vectorial y filtros estructurados (Q3 de *2_2_Semantic_Retrieval_RAG.pdf* y *Filter context* de Elasticsearch).

Opción 2.3 — Benchmarking Large Language Models in Retrieval-Augmented Generation

CORE A* (AAAI)

Autores: Jiawei Chen, Hongyu Lin, Xianpei Han, Le Sun (Chinese Academy of Sciences) · **Año:** 2024 · **Publicación:** *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI 2024)*, Vol. 38, No. 16, pp. 17754–17762.

DOI Oficial: https://doi.org/10.1609/aaai.v38i16.29728

PDF Completo (AAAI): https://ojs.aaai.org/index.php/AAAI/article/download/29728/31250 **arXiv:** https://arxiv.org/pdf/2309.01431

- **Problema de investigación:** Cómo evaluar sistemáticamente los modos de fallo de los sistemas **RAG** cuando los pasajes recuperados contienen ruido léxico/semántico, información contradictoria o evidencia insuficiente para responder.
- **Contribución científica:** Introduce el benchmark **RGB** que mide 4 capacidades fundamentales en RAG: *Noise Robustness*, *Negative Rejection* (reconocer evidencia insuficiente), *Information Integration* y *Counterfactual Robustness*, demostrando las limitaciones actuales de los LLMs al sintetizar contexto recuperado.
- **Conexión con la asignatura:** Desarrolla en profundidad la diapositiva 29 de *2_2_Semantic_Retrieval_RAG.pdf* (*"RAG Failure Modes and Evaluation: Retrieval Failure, Generation Failure, Insufficient Evidence"*).

BLOQUE III: Gobernanza e Interoperabilidad (RDF, OWL, RML, Helio, SPARQL, Data Spaces y ODRL)

Opción 3.1 — Morph-KGC: Scalable knowledge graph materialization with mapping partitions

★ RECOMENDADO BLOQUE III (UPM) · JCR Q1 (SEMANTIC WEB)

Autores: Julián Arenas-Guerrero, David Chaves-Fraga, Jhon Toledo, María S. Pérez, Oscar Corcho (Ontology Engineering Group - UPM) · **Año:** 2024 · **Publicación:** *Semantic Web*, Vol. 15, No. 1, pp. 1–20.

DOI Oficial: https://doi.org/10.3233/SW-223135

PDF Completo (Semantic Web): https://www.semantic-web-journal.net/system/files/swj3135.pdf

arXiv: https://arxiv.org/pdf/2202.02596

- **Problema de investigación:** La generación de grafos **RDF** a partir de fuentes de datos masivas y heterogéneas (CSV, JSON, XML, SQL) mediante lenguajes declarativos como **RML (`rml.io`)** sufre problemas severos de escalabilidad en tiempo y memoria al eliminar tripletas duplicadas y ejecutar *joins* entre fuentes.
- **Contribución científica:** Propone **Morph-KGC** y la técnica formal de *particionado de reglas de mapeo (mapping partitions)*, que identifica grupos de reglas RML que generan conjuntos disjuntos de tripletas RDF para materializarlos en paralelo reduciendo drásticamente el consumo de RAM y el tiempo de ejecución.
- **Conexión con la asignatura:** Escrito en el propio grupo OEG de la UPM; conecta directamente con la diapositiva 15 de *[3.2] Block 3.2.pdf* (**RDF Generation con RML**) y con la escalabilidad de datos masivos del Bloque I.

Opción 3.2 — Helio: A framework for implementing the life cycle of knowledge graphs

★ HERRAMIENTA DE CLASE (UPM) · JCR Q1 (SEMANTIC WEB)

Autores: Andrea Cimmino, Raúl García-Castro (Ontology Engineering Group - UPM) · **Año:** 2024 · **Publicación:** *Semantic Web*, Vol. 15, No. 6, pp. 2233–2259.

DOI Oficial: https://doi.org/10.3233/SW-233224 **PDF Completo (Repositorio Oficial UPM):** https://oa.upm.es/90399/1/HELIO.pdf

- **Problema de investigación:** Cómo integrar y mantener actualizado el ciclo de vida completo de un Grafo de Conocimiento (**RDF/OWL**) cuando los datos provienen tanto de ficheros estáticos como de APIs REST y flujos de datos dinámicos en tiempo real (IoT, Smart Cities), incluyendo validación y publicación **SPARQL**.
- **Contribución científica:** Presenta la arquitectura y motor declarativo de **Helio**, separando la ingesta (conectores asíncronos/síncronos), la traducción sintáctica/semántica a RDF, la validación (SHACL) y la federación SPARQL, superando en rendimiento a los motores RML tradicionales en escenarios dinámicos.
- **Conexión con la asignatura:** Es el artículo científico oficial de la herramienta **Helio (`helio-playground.linkeddata.es`)** mostrada en la diapositiva 15 de *[3.2] Block 3.2.pdf*, escrito por los mismos autores citados en la diapositiva 9.

Opción 3.3 — Interoperable Interpretation and Evaluation of ODRL Policies

CORE A (ESWC 2025)

Autores: Wout Slabbinck, Julián Andrés Rojas Meléndez, Beatriz Esteves, Pieter Colpaert, Ruben Verborgh (Ghent University - IDLab) · **Año:** 2025 · **Publicación:** *The Semantic Web – ESWC 2025 (Main Research Track)*, LNCS, Springer.

DOI Oficial: https://doi.org/10.1007/978-3-031-94578-6_11 **PDF Completo (Acceso Abierto):** https://arxiv.org/pdf/2503.00514

- **Problema de investigación:** En los **Espacios de Datos (*Data Spaces*)**, el estándar W3C **ODRL 2.2** se utiliza para definir políticas de acceso y uso (*Interoperability at Contracting*), pero carece de una especificación formal de evaluación, provocando que dos conectores distintos evalúen una misma política ODRL de forma contradictoria.
- **Contribución científica:** Define un modelo formal de evaluación de políticas ODRL basado en el estado del mundo en RDF, un vocabulario de *Compliance Report* trazable y un evaluador de código abierto validado frente a los casos de prueba del W3C ODRL Community Group.
- **Conexión con la asignatura:** Cubre directamente el apartado 4.3 del Bloque III en *4_Workshop.pdf* (**Data Spaces y Políticas ODRL**) y las diapositivas 4–8 de *[3.2] Block 3.2.pdf* (*Control Plane*, *Usage Policies* e *Interoperability at Contracting*).

Bloque	Top Recomendación	Por qué elegirlo para el Póster del Workshop
Bloque I · Almacenamiento	**Opción 1.1** (*PVLDB 2024* · CORE A*/Q1)	Ataca directamente las limitaciones transaccionales ACID de **Apache Hive** vistas en clase con gráficas de rendimiento muy visuales.
Bloque II · Recuperación (IR/RAG)	**Opción 2.1** (*ACM TOIS 2023* · JCR Q1)	Explica y compara matemáticamente **BM25 + Embeddings (Score Fusion vs. RRF)** con las métricas exactas del curso (**nDCG@10, Recall@k**).
Bloque III · Gobernanza y Semántica	**Opción 3.1 (Morph-KGC)** o **3.2 (Helio)** (*Semantic Web 2024* · JCR Q1)	Publicados en revista Q1 por investigadores del grupo OEG de la UPM sobre las herramientas exactas (`rml.io` y `helio`) de las diapositivas de clase.